

Quem disse isso?

Verificação condicionada ao orador e desempenho lexicográfico
para detectar alucinações em audiências públicas

Gabriel Ribeiro¹ Cauã Sathler² Arthur Gonçalves¹ Jordan Elias³

¹Colab Domain-Specific Foundation Models, DCC-UFMG ²Colab Agentic AutoML for Data Science, DCC-UFMG

³Colab SLMs for Process Automation, Universidade Federal do Ceará (UFC)

Desafio **Ideias em Rede (1ª Edição)** — Instituto Kunumi

Setembro de 2026

O problema: opiniões atribuídas à pessoa errada

Um resumo diz que o deputado X defendeu Y. Ele disse mesmo?

206 audiências

Transcrições da Câmara
dos Deputados

4.238 opiniões

Cada uma atribuída a
um participante

11,9% alucinações


Não suportadas pela
transcrição (rótulo
humano)

12 juízes LLM

Voto binário; comitê:
AUROC 0,926

Métrica: **AUROC**, a chance de uma alucinação receber nota mais alta que uma opinião suportada (0,5 = acaso; 1 = perfeito).

Por que detectores baratos falham: a melhor frase é de outra pessoa



Observação (cegueira de incidência)

Máximo, média ou top- k sobre as frases não sabem *quem* falou cada frase: trocar os nomes dos oradores não muda a nota. Por isso ficam em 0,57 (similaridade) e 0,58 (NLI).

Ideia 1: comparar a opinião com as falas de quem supostamente a disse

Sinal	Custo	AUROC
Melhor frase da audiência (baseline)	0	0,568
Melhor entailment da audiência (baseline)	10 NLI	0,583
Melhor frase do orador atribuído	0	0,746
Escore de má-atribuição Δ	0	0,760
Todas as features de orador	0	0,761
+ 2 features NLI	10 NLI	0,779

Controles

Orador *aleatório* da mesma audiência:
0,521 (acaso).

O sinal vem de **quem** falou, não de
quanto falou.

Auditoria de 50 positivos

Cerca de **1 em cada 4** alucinações é
má-atribuição; nelas $\Delta > 0$ sempre.

+0,18 de AUROC sem chamar nenhum modelo.

Os juízes empatam: o espaço que um desempate pode usar



Soma de 12 votos binários: só 13 valores possíveis.

Um par (alucinação, suportada) com o mesmo número de votos está **empatado**.

$\tau = 4,65\%$ dos pares

Ganho máximo de um desempate:
 $\tau/2 = 0,023$

Com **1 juiz**, τ chega a $\approx 26\text{--}38\%$: muito mais espaço.

Somar as notas inverte decisões; desempatar, não

	x	y	z
votos dos juízes	4	5	5
sinal barato	0,95	0,10	0,90
soma ponderada	1,28	0,52	1,32
⇒ x (4 votos) passa à frente de y (5 votos)			
lexicográfico	(4; 0,95)	(5; 0,10)	(5; 0,90)
⇒ mantém os votos; só separa y e z			

Nos 1,3 milhão de pares (12 juízes)

Stacking: ganha +0,0017 nos empates, perde -0,0014 invertendo 1,33% dos pares ⇒ +0,0002.

Lexicográfico: +0,0040, **zero** inversões.

Mesma informação; a diferença é poder ou não contrariar os juízes.

Ideia 2: o desempate lexicográfico e o seu ganho exato

Regra

Ordene pelos votos dos juízes; entre opiniões com o mesmo número de votos, ordene pelo sinal barato.

Decomposição (elementar) do AUROC

$$\text{AUROC}(\text{juízes} \preceq_{\text{lex}} \text{sinal}) = \text{AUROC}(\text{juízes}) + \tau \left(\alpha - \frac{1}{2} \right)$$

τ : fração de pares empatados (vem só dos votos). α : AUROC do sinal barato **dentro dos empates**.

Comitê de 12 juízes


0,9260 $\rightarrow$ **0,9300**

acima do comitê em 20 de 20 partições (stacking:
1 de 20)

O que importa é α

A AUROC global do sinal barato não entra na fórmula.

O resultado principal: poucos juízes com desempate chegam perto de doze



1 juiz

0,807 → **0,881**


todos os 12 juízes melhoram (+0,046 a +0,102; IC > 0)

7 juízes + desempate

estatisticamente empatado com os 12
(+0,0001, IC [-0,005; +0,005])

Medianas sobre 60 subconjuntos aleatórios de juízes; análise exploratória.

Na fila de revisão, o desempate encontra mais alucinações



Revisando 10% da fila

40,5% → **52,2%** das alucinações
com uma única chamada de juiz

Um voto binário não ordena as opiniões dentro de cada resposta: sem o desempate, a fila é aleatória ali.

O ganho pode ser previsto antes de usar a regra

Juízes	observado	previsto com α	com AUROC global
1	+0,072	+0,071	+0,100
3	+0,028	+0,027	+0,049
5	+0,015	+0,015	+0,031
8	+0,008	+0,007	+0,019
12	+0,004	+0,004	+0,013

50 divisões aleatórias das audiências: α medido numa metade, τ e o ganho observados na outra.

Sem viés

Sinal do ganho certo em 99% dos 250 casos.

Usar a AUROC global superestima o ganho de 1,4 a 3 vezes.

O que não funcionou e os limites

Resultados negativos (reportados)

- 5 features estruturais (homologia, Hodge...): nada acrescentam ao comitê.
- 6 tentativas de melhorar α : todas pioram.
- Com 12 juízes, a fila de revisão não melhora de forma mensurável.

Limites

- Rótulos do PublicHearingBR usados como dados.
- Ganho sobre os 12 juízes é pequeno (+0,004), mas consistente.
- Onde o comitê erra, o sinal barato erra junto (0,47).

Predições registradas no repositório antes de cada experimento.

Detecção confiável com uma fração do custo

Contribuições

1. Features de orador: $0,57 \rightarrow 0,76$ sem LLM.
2. Desempate que nunca contraria os juízes.
3. Ganho exato e previsível: $\tau(\alpha - \frac{1}{2})$.
4. 1 juiz: $0,81 \rightarrow 0,88$; 7 juízes ≈ 12 .

Materiais

Artigo, código e dados em
[github.com/caua-sathler/
IdeiasEmRede-TopoIA](https://github.com/caua-sathler/IdeiasEmRede-TopoIA)

Painel interativo: [apresentacao/dashboard](#)

Muito obrigado!

Gabriel Ribeiro · Cauã Sathler · Arthur Gonçalves · Jordan Elias
DCC-UFMG · UFC